

멀쩡해 보이는 배터리에서 수명 신호를 찾는다

ESS 배터리 교체 계획을 위한 초기 수명 예측 — 탐색적 분석과 모델 설계

ESS에서 배터리 교체 비용은 설치비의 30~40%를 차지한다(과제 자료). 그래서 이번 분석은 "용량이 눈에 띄게 줄기 전인 100사이클 시점에 전체 수명을 맞힐 수 있는가"를 질문으로 잡고, 세 개 배치(139개 셀)를 살펴본 뒤 모델 설계 방향을 정했다.

+0.2% 100사이클 시점 용량 변화	-0.84 ΔQ 분산-수명 상관 (Batch 1)	24% Batch 2 일부 수명 차이	9.1% 목표 MAPE (원논문)
---------------------------------	---	--------------------------------	------------------------------

이 보고서에서 말하고 싶은 것

- 100사이클 시점의 배터리는 용량만 보면 거의 다 똑같다. 그런데 방전 곡선 모양의 변화(ΔQ)에는 이미 수명 차이가 보인다. 그래서 ΔQ 를 중심으로 수명 예측 모델을 만들 계획이다.
- 배치가 바뀌면 같은 ΔQ 값이어도 수명이 다르게 나온다. 특히 Batch 2 일부는 Batch 1 기준보다 24% 정도 짧게 살았다. DAY 2 테스트에서는 수명을 길게 예측하는 쪽으로 틀릴 가능성이 높다고 보고, 결과를 그룹별로 나눠 보려고 한다.
- 이 데이터는 실험실에서 고속충전으로 돌린 결과라 실제 ESS에 바로 쓰기는 어렵다. 운영에 쓸 만한 가설(무류점 위치, 충전 전류 분배)은 얻었지만, 현장 데이터로 다시 확인해야 한다.
- 모델은 $\log(\text{수명})$ 을 타깃으로, ΔQ 분산 하나를 쓰는 선형 회귀를 주력으로 하고, 피처를 늘릴 때만 ElasticNet으로 중복을 규제한다. 같은 충전 방식의 배터리는 학습과 검증 중 한쪽에만 넣어 데이터 누수를 막는다. 학습 셀이 36개뿐이고 예측 이유를 설명할 수 있어야 해서 딥러닝은 쓰지 않는다.

사양

데이터셋	MIT-Stanford (2019)
셀 화학계	LFP / 흑연 18650
공칭 용량	1.1 Ah
수명 기준	0.88 Ah (80%)
전체 · 사용 셀	139 · 119
예측 시점	100 사이클
과제 유형	회귀 (cycle_life)
목표 MAPE	9.1 %

재현 코드: notebooks/01_EDA.ipynb · src/ · DECISIONS.md

데이터: Severson et al., Nature Energy 4, 383–391 (2019)

과제 질문별로 어디에 답했는지

과제 요구	핵심 답	위치
① 수명 분포	배치마다 수명 범위가 크게 다름. 짧은 쪽 이상치는 없고, Batch 2는 두 실험 방식이 섞여 있음	4.1
② 열화 곡선	100사이클까지는 용량 차이가 거의 없음. 후반에 급가속하고, 무릎점은 수명의 약 70%	4.2
③ ΔQ(V)	단수명일수록 곡선이 크게 휘어짐. log 분산이 가장 쓸 만한 피쳐 (-0.84 / -0.92 / -0.76), 배치별 분포도 수명 순서와 일치	4.3
④ 충전 조건	빨리 충전할수록 단수명·초기 열화가 빠름. 충전 시간이 같아도 전류를 몰면 단수명	4.4
⑤ 상관·다중공선성	배치가 바뀌어도 방향이 같은 건 ΔQ뿐. ΔQ 통계끼리 중복이 커서 대표 1개 또는 규제로 처리	4.5
배치 간 비교	Batch 3는 Batch 1과 비슷, Batch 2 기존 방식은 약 24% 단수명 → DAY 2 과대예측 위험	4.6
피쳐 선별	log Var(ΔQ) 중심, 평균·최대 C-rate 보조. 부호가 바뀌는 피쳐는 비교용으로만	5.1
회귀/분류, 타깃	회귀, 타깃은 log10(cycle_life)	1.1, 5.1
모델링 전략	기준선 → ΔQ 단일 선형 회귀(주력) → ElasticNet(피쳐 확장 시), 트리는 비교. 정책 단위 분할, 선택 기준 명시	5.2, 5.3

자주 나오는 용어

용어	뜻
사이클 / 수명	완전 충전 1번 + 완전 방전 1번 / 용량이 새것의 80%(0.88Ah)가 될 때까지 쓴 사이클 수
ΔQ(V)	같은 배터리의 100번째와 10번째 방전 곡선의 차이. "90번 쓰는 동안 곡선 모양이 얼마나 변했나"
C-rate	충전 속도. 1C는 약 1시간, 4C는 약 15분에 완충
무릎점	천천히 줄던 용량이 갑자기 빠르게 줄기 시작하는 지점
중도 절단	수명이 끝나기 전에 실험 기록이 끝난 경우
MAPE / Gap	예측이 실제 수명에서 평균 몇 % 벗어났는지 / 학습·검증·테스트 사이의 성능 차이
다중공선성 / VIF	피쳐끼리 같은 정보를 겹쳐 담고 있는 것 / 그 정도를 나타내는 값(10 이상이면 중복이 심함)

1. 과제 배경과 문제 정의

1.1 누가, 어떤 결정에 쓰는가

분석 전에 이 결과를 누가 어떤 결정에 쓰는지부터 정리했다. 그래야 회귀와 분류 중 무엇을 고를지, 어떤 지표를 볼지, 결과를 어떻게 전달할지가 정해진다.

항목	정의
사용자	ESS 운영사 — 배터리 교체 계획과 예산을 맡은 운영팀
현재의 문제	예측 없이 운영하면 ① 갑작스러운 수명 종료로 설비가 멈추거나 ② 불필요한 예방 교체로 비용이 늘고 ③ 용량 저하를 놓쳐 피크 대응에 실패한다 (과제 도메인 자료)

항목	정의
의사결정	셀·랙 교체 시점과 예산을 미리 계획
분석 질문	초기 100사이클 정보만으로 전체 수명(cycle_life)을 예측할 수 있는가? 예상 잔여 수명(예측 전체 수명 - 100)을 교체 계획에 쓸 수 있는가?
성공 기준	원논문 수준(MAPE 9.1%)에 근접하고, 다른 배치에서 성능이 떨어지면 그 원인을 설명할 수 있을 것

분류가 아니라 회귀를 고른 이유

원논문은 두 방식을 모두 다룬다. 회귀는 100사이클로 전체 수명을 예측하고, 분류는 5사이클로 550사이클 이상/미만을 나눈다. 분류는 더 빨리 판단할 수 있어서 제조사가 출하 전에 셀을 고르는 데는 유리하다. 하지만 운영사의 교체 계획에는 "오래 간다/짧다"보다 "몇 사이클 남았는가"라는 숫자가 필요하다. 그래서 사용자의 의사결정을 기준으로 회귀를 골랐다. Batch 2가 550 미만에 몰려 있어 분류 평가가 어렵다는 점은 선택 이유가 아니라, 세 배치를 비교하면서 확인한 추가 위험으로 따로 적었다.

1.2 이 데이터로 ESS를 이야기해도 되는가

이 데이터는 원래 전기차 급속충전 연구를 위해 만든 것이다. 그래서 ESS 관점에서 그대로 써도 되는지 먼저 따져 봤다. 배터리 화학계가 같아서 출발점으로는 써도 된다고 봤다. 다만 운용 조건이 꽤 달라서, 그 차이는 결과를 해석하거나 운영 제안을 할 때 같이 적었다.

구분	이 데이터 (실험실)	실제 유틸리티 ESS	판단
화학계	LFP / 흑연	고정형 저장은 LFP 중심	같은 계열 → 출발점으로 적합
충방전 속도	충전 3.6~8C (0→80% 약 8~13분), 방전 4C	2~10시간에 걸친 충방전 (약 0.1~0.5C)	실험이 훨씬 가혹 → 열화 양상이 다를 수 있음
방전 방식	매 사이클 완전 방전	부분 충방전이 일반적	ΔQ를 얻으려면 별도 측정 절차가 필요
온도·시간	30℃ 챔버, 쉬지 않고 연속 실험	계절 변동, 수년 운용(시간 노화)	추가 검증 필요

출처: 데이터 공개처 실험 설명(Kaggle/원 저장소), NREL Annual Technology Baseline 2024 — Utility-Scale Battery Storage (2~10시간 시스템, 2022년 이후 고정형 저장의 주력 화학계는 LFP)

2. 데이터 이해와 정리 — 정답을 믿을 수 있는가

모델은 정답(cycle_life)을 보고 배운다. 그래서 그래프를 그리기 전에 정답 자체를 믿을 수 있는지부터 확인했다. 셀마다 기록이 끝난 시점에 용량이 수명 기준(0.88Ah)에 실제로 도달했는지를 봤다.




그림 1. 배치별 셀 상태(왼쪽)와 Batch 1 용량 곡선(오른쪽). 빨간 선 10개는 수명 기준선(점선)에 닿기 전에 기록이 끝났다.

배치	전체	정상	정답 없음	수명 기준 도달 전 실험 종료	정상 셀 수명 (중앙값, 범위)
Batch 1 (학습)	46	36	0	10	773 (534~1,074)
Batch 2 (테스트)	47	39	8	0	472 (392~1,186)
Batch 3 (추가 테스트)	46	44	2	0	1,006 (541~1,935)

확인해 보니 문제가 세 가지 있었다. 첫째, Batch 1의 10개 셀은 용량이 0.88Ah에 도달하기 전에 기록이 끝났다. 이 셀들에 적힌 cycle_life는 실제 수명이 아니라 실험이 멈춘 시점이다. 데이터 공개처의 실험 노트("일부 채널은 중단 후 다른 배치에서 재개", "일부 채널은 80% 도달 전 종료")와도 맞는다. 둘째, Batch 2의 8개(VarCharge·SLOWCYCLE 등 다른 실험 방식)와 Batch 3의 2개는 정답이 비어 있다. 셋째, 한두 사이클에서만 용량이 튀는 측정 오류가 2건 있었다(12번째, 40번째 사이클).

실험이 중간에 끝난 10개 셀의 처리

쉽게 떠오르는 방법은 그대로 쓰거나 빼는 것인데, 둘 다 문제가 있었다. 그대로 쓰면 "1,190사이클에서 수명이 끝났다"는 틀린 값을 정답으로 배우게 된다. 마라톤으로 치면, 대회가 비 때문에 30km에서 취소됐는데 기록표에 "30km에서 완주 실패"라고 적는 셈이다. 그렇다고 빼려고 보니, 이 10개가 모두 정상 셀보다 오래 버틴 장수명 셀이었다. 빼면 Batch 1의 최대 수명이 1,227에서 1,074로 줄어서, 모델이 긴 수명을 짧게 보는 쪽으로 기울 수 있다.

이렇게 끝까지 지켜보지 못한 데이터를 중도 절단(censored) 데이터라고 부른다. 보통 ① 빼기, ② "최소 이만큼은 살았다"는 정보로 쓰기, ③ 용량 곡선을 이어 그려 수명 추정하기, ④ 생존 분석 중 하나로 처리한다. 실제 ESS 현장 배터리는 대부분 아직 쓰는 중이라 결국 ③·④가 필요할 것이다. 이번에는 이를 안에 끝내야 해서 ①과 ②를 같이 썼다. 학습과 평가에서는 빼되, 나중에 모델이 이 배터리들의 수명을 기록 길이보다 짧게 예측하면 확실히 틀린 것으로 보고 점검하는 데 쓴다. ③·④는 실제 운영 단계에서 해 볼 과제로 남겨 뒀다.

측정 오류는 앞뒤 사이클 값으로 보간하고 셀은 그대로 썼다. 피쳐 계산에 쓰는 10번째·100번째 방전 곡선은 정상인 것을 확인했다. 최종적으로 학습 36개, 테스트 39개, 추가 테스트 44개를 사용한다.

3. 분석 원칙 — 예측 시점에 알 수 있는 정보만 쓴다

과제 예시(배달 매출 예측)에서는 실제 날씨 대신 예보를 썼다. 예측하는 시점에는 실제 날씨를 알 수 없기 때문이다. 배터리도 마찬가지로, 100사이클 시점에 수명을 예측한다면 101번째 사이클 이후 정보는 쓸 수 없다. 이걸 안 지키면 실험에서는 성능이 좋게

나와도, 실제로 쓸 때는 그 성능이 안 나온다. 그래서 분석 전체에 아래 네 가지 규칙을 적용했다.

규칙	내용	이유
타깃 (Y)	cycle_life = 방전 용량이 0.88Ah(공칭 1.1Ah의 80%)에 도달한 사이클. 학습은 log10 변환	SOH 80%는 이 데이터와 원논문의 EOL 기준. 실제 ESS 교체 기준은 계약·운영 조건에 따라 다름
입력 (X)	1~100사이클 기록만 사용. 1번 사이클(Batch 1은 기록이 0)은 제외	예측 시점 이후 정보 차단
피쳐 결정	후보 피쳐와 기준값은 원논문, 과제 정의, Batch 1을 보고 정했다. Batch 2·3은 배치끼리 뭐가 다른지 확인하는 데만 썼다	테스트 배치 정보가 모델에 섞이지 않게 하려고
검증 분할	같은 충전 정책의 셀은 항상 같은 쪽(학습 또는 검증)에 둔다	Batch 1은 정책당 셀이 평균 1.8개라 무작위로 나누면 거의 같은 셀이 양쪽에 들어가 누수가 생김 (과제 노트의 경고)

4. 탐색적 분석 — 다섯 가지 질문

과제의 다섯 가지 질문을 순서대로 확인했다. 질문마다 왜 이걸 봐야 하는지, 무엇이 보였는지, 그 결과를 모델과 운영에 어떻게 반영할지를 정리했다. 모든 분석은 세 배치를 함께 놓고 비교했다.

4.1 수명 분포 — 학습과 시험이 같은 문제인가

모델은 학습 데이터 범위 안에서 가장 잘 맞는다. 그래서 수명 분포가 배치마다 어떻게 다른지를 보면 테스트가 얼마나 어려운 시험인지 미리 알 수 있다.




그림 2. 배치별 수명 분포(왼쪽, 150~2,300사이클)와 실험 방식별 수명(오른쪽). Batch 2는 짧은 그룹과 긴 그룹이 섞여 있다.

배치	수명 범위	장수명(>1,000) 비율	단수명(<500) 비율	이상치 (배치별 IQR 기준)
Batch 1	534~1,074	14%	0%	없음
Batch 2	392~1,186	8%	72%	긴 쪽 9개 (전부 newstructure)
Batch 3	541~1,935	52%	0%	긴 쪽 3개 (4.8C(80%)-4.8C, 5C(67%)-4C)

- 짧은 쪽으로 벗어난 이상치는 세 배치 모두 없었다. 상대적으로 짧게 산 셀은 Batch 1의 5.4C(80%)-5.4C(534, 559), 8C(35%)-3.6C(599)와 Batch 3의 3.7C(31%)-5.9C(541)였다. 처음부터 끝까지 빠르게 충전하거나, 한 구간에서 아주 높은

전류로 충전하는 정책이다(4.4절에서 확인).

- Batch 2에서 이상치로 잡힌 장수명 셀 9개는 정책명에 모두 newstructure가 붙어 있었다. Batch 3과 같은 실험 방식이다. 즉 Batch 2는 기존 방식 30개(중앙값 451)와 newstructure 9개(중앙값 904)가 섞인 배치다.
- 같은 충전 정책인데 배치가 다르면 수명 차이가 컸다. 6C(60%)-3C 정책은 Batch 1에서 평균 744사이클, Batch 2에서 400사이클이었다.

설계 반영

- 다른 배치에는 학습 범위 밖의 수명이 많다. 트리 계열 모델은 학습 범위 밖을 예측하기 어려워서 이 부분을 위험 요소로 메모해 뒀다. DAY 2에서는 선형 계열과 트리 계열을 모두 후보로 두고, 최종 선택은 Batch 1 검증 결과로 한다.
- 타깃은 log로 변환한다. 배치 간 수명 스케일이 2배 이상 다르고 평가 지표도 상대오차(MAPE)다. 정상 셀 전체의 왜도가 1.05에서 0.03으로 줄었다.
- 충전 정책만으로는 배치 차이가 설명되지 않는다. 생산 로트나 운영 조건이 바뀌면 같은 제품도 수명이 달라지는 것과 비슷하다. DAY 2에서 성능 차이가 나면 가장 먼저 의심해 볼 원인이다.

4.2 열화 곡선 — 초반 용량으로 수명을 맞힐 수 있는가

교수님 예시 노트북에도 "초기 구간에서는 곡선이 겹친다"는 관찰이 있었다. 이걸 세 배치로 넓혀서 숫자로 확인했고, 열화 속도가 일정한지, 급락이 어디서 시작되는지도 같이 봤다.




그림 3. 배치별 용량 곡선(색이 밝을수록 장수명). 노란 구간(1~100사이클)에서는 장수명과 단수명 곡선이 겹친다. 빨간 점은 무릎점이다.

- 2~100사이클 용량 변화의 중앙값은 +0.2%로 오히려 늘었다. 원논문 초록의 내용과 같다. 100사이클 시점에는 모든 배터리가 멀쩡해 보인다.
- 열화는 일정하지 않고 끝으로 갈수록 빨라진다. 수명 말기 100사이클의 용량 감소 속도는 초기보다 약 135배(Batch 1), 132배(Batch 3) 빨랐다.
- 무릎점은 수명의 65~76% 지점에 있었다(Batch 1 중앙값 71%). 배치별 중앙값도 71~76%로 비슷했고, 무릎점 위치와 수명의 상관은 0.98 이상이었다(부록 그림 A1). 무릎점은 용량 곡선을 부드럽게 다듬은 뒤, 처음과 끝을 이은 직선에서 가장 멀리 떨어진 점으로 잡았다.
- 초기 용량 감소 속도와 수명의 상관은 Batch 1에서 -0.51, Batch 2에서 +0.45로 배치마다 방향이 반대였다.

무릎점으로 예측하면 안 되는가

무릎점 위치가 이렇게 일정하면 무릎점으로 예측하면 되지 않을까 싶었다. 하지만 무릎점은 곡선이 꺾인 **뒤에야** 알 수 있다. 수명 800사이클짜리 배터리라면 570사이클쯤 돼서야 보인다. 하루 1회 충방전을 가정하면, 그때부터 남은 7~8개월 안에 예산과 부품을 준비해야 한다는 뜻이다. 결국 무릎점은 100사이클 조기 예측을 대신할 수 없고, 오히려 꺾이기 전에 알려 주는 예측이 왜 필요한지를 보여 준다. 실제 경보 기준으로 쓰려면 현장 데이터로 따로 확인해야 한다.

설계 반영

- 용량 값만으로는 구분이 안 되고, 초기 감소 속도는 배치마다 방향이 바뀐다. 그래서 둘 다 비교용으로만 두고, 곡선 모양의 변화를 따로 본다(4.3절).

4.3 $\Delta Q(V)$ 곡선 — 용량은 같아도 모양은 다르다

용량 값에 차이가 없다면 남은 단서는 방전 곡선의 모양이다. 배터리를 방전하면 전압이 3.5V에서 2.0V로 떨어지는데, 각 전압까지 전기가 얼마나 나왔는지를 1,000개 점으로 기록한 게 Qdlin 곡선이다. 같은 배터리의 100번째 곡선에서 10번째 곡선을 빼면 $\Delta Q(V)$ 가 된다. 같은 사람의 1월과 4월 건강검진 결과를 비교하는 것과 비슷하다. 겉으로는 둘 다 건강해 보여도 수치가 미세하게 변했다면 먼저 아플 가능성이 높다. 같은 배터리끼리 빼는 값이라, 과제 노트에서 주의하라고 한 배치별 Qdlin 시작점 차이는 상당 부분 상쇄될 것으로 본다(따로 검증하지는 않았다).




그림 4. 배치별 $\Delta Q(V) = Q_{100} - Q_{10}$ 곡선. 어두운 선(단수명)일수록 2.9~3.0V 부근에서 더 깊게 휘어진다.




그림 5. ΔQ 분산과 수명(왼쪽), ΔQ 계산 구간을 앞당겼을 때의 상관 변화(오른쪽).

ΔQ 통계 (log 수명과의 상관)	Batch 1	Batch 2	Batch 3
log 분산	-0.84	-0.92	-0.76
log 최소값	-0.82	-0.90	-0.74
log 평균	-0.77	-0.87	-0.65
왜도 / 첨도	-0.43 / 0.02	-0.13 / 0.65	0.19 / 0.34

- 단수명 셀일수록 ΔQ 곡선이 크게 휘어졌다. 겉으로 보이는 용량은 같아도 내부에서는 변화가 이미 진행되고 있다는 뜻이다.
- log 분산은 세 배치 모두에서 강했고 방향도 같았다. Batch 1·3에서는 가장 강한 신호였다. Batch 2에서는 충전 시간(-0.94)이 조금 더 강했는데, 이걸 4.5절에서 보듯이 그룹이 섞여서 생긴 상관이다. 원본문이 핵심 피처로 쓴 신호를 이 데이터에서도 다시 확인한 셈이다.
- Batch 2의 -0.92는 대부분 두 그룹(기존 방식/newstructure) 사이의 차이에서 나온다. 기존 방식 30개만 따로 보면 -0.38이다. 수명이 392~514로 좁게 몰려 있어서 구분할 차이 자체가 작다.




그림 6. 핵심 변수(ΔQ 분산)의 배치별 분포. 오른쪽(곡선 변화가 큰 쪽)에 있는 그룹일수록 수명 중앙값이 짧다.

핵심 변수 자체의 분포도 배치마다 달랐다. Batch 2 기존 방식은 ΔQ 분산이 가장 크고(중앙값 -3.46) 수명도 가장 짧다(451). Batch 1은 중간(-3.79, 773), Batch 3과 Batch 2 newstructure는 분산이 작고(-4.18, -4.23) 수명이 길다(1,006, 904). 그룹의 순서가 수명 순서와 그대로 맞아서, ΔQ가 수명을 반영한다는 점이 분포에서도 보인다.

예측 시점을 앞당길 수 있는가

운영사 입장에서는 더 일찍 알수록 좋으니, ΔQ 계산 구간을 20·30·50사이클로 앞당겨 봤다. Batch 1에서는 50사이클도 상관 -0.75로 괜찮았지만, Batch 2·3에서는 -0.6 수준으로 약해졌고 20사이클에서는 Batch 3의 방향이 아예 바뀌었다(+0.19). 공부한 배치에서만 잘 맞는 신호는 다른 배치에서 믿기 어렵다. 그래서 이 결과는 피처를 고르는 데 쓰지 않았고, DAY 2 메인 모델은 과제 정의대로 100사이클을 쓴다. 50사이클은 "더 빠르지만 덜 정확한" 선택지로 나중에 따로 확인해 볼 생각이다.

설계 반영

- 핵심 피처는 $\log_{10} \text{Var}(\Delta Q_{100-10})$ 이다. 최소값·평균은 분산과 사실상 같은 정보다(4.5절).
- $\log \Delta Q$ 분산과 $\log$ 수명의 관계가 직선에 가깝다. 선형 모델로도 충분히 설명할 수 있는 구조라서 모델 선택의 근거로 삼았다.

4.4 충전 조건 — 고속충전은 정말 수명을 줄이는가

"급속충전을 하면 배터리가 빨리 닳는다"는 이미 알려진 이야기라, 이것만 확인해서는 새로운 정보가 되기 어렵다. 그래서 "얼마나 빨리"가 문제인지, "어떻게 나눠서"가 문제인지로 질문을 나눴다. 충전 정책 문자열(예: 8C(35%)-3.6C는 0→35%를 8C로, 35→80%를 3.6C로 충전)을 두 개의 숫자로 바꿨다. 0→80% 평균 C-rate는 충전 시간을, 최대 C-rate는 가장 세게 충전하는 구간의 속도를 나타낸다.




그림 7. Batch 1 정책별 평균 수명(왼쪽), 평균 C-rate와 수명(가운데), 충전 시간이 같은(약 10분) 셀들의 최대 C-rate와 수명(오른쪽).

- Batch 1은 충전 시간이 8~13분으로 다양하다. 평균 C-rate ≤ 4.4 에서 평균 수명 879, 4.4~4.8에서 751, 4.8 초과에서 643사이클이었다($r = -0.58$). 첫 단계와 둘째 단계 속도를 하나씩 따로 보면 관계가 약했다($r \approx -0.24$).
- 충전 시간이 같아도 최대 C-rate가 높을수록 수명이 짧았다. 약 10분 충전 셀만 보면 Batch 1에서 $r = -0.68$, Batch 3에서 $r = -0.66$ 으로 두 배치에서 같은 방향이었다. Batch 3에서는 4.8C로 일정하게 충전한 셀이 평균 1,564사이클로 가장 오래 살았고, 후반에 5.9C로 몰아서 충전한 셀은 660사이클로 가장 짧았다.
- Batch 2·3은 모든 정책이 같은 충전 시간(평균 4.8C)으로 설계되어 있다. 그래서 이 두 배치에서는 평균 C-rate로 셀 간 차이를 설명할 수 없다.

과제에서 요구한 "충전 전류 패턴과 열화 속도의 상관"도 따로 확인했다. 열화 속도는 초기(2~100사이클)와 수명 말기(수명 종료 직전 100사이클)의 용량 감소 속도로 봤다.

충전 지표 ↔ 열화 속도 (상관)	Batch 1	Batch 2	Batch 3
평균 C-rate ↔ 초기 감소 속도	0.62	0.33	-0.27

충전 지표 ↔ 열화 속도 (상관)	Batch 1	Batch 2	Batch 3
평균 C-rate ↔ 말기 감소 속도	0.38	-0.20	0.27
최대 C-rate ↔ 초기 감소 속도	0.02	0.41	0.43
최대 C-rate ↔ 말기 감소 속도	0.13	-0.06	0.22

- 충전 시간이 다양한 Batch 1에서는 빠르게 충전할수록 초기 용량이 더 빨리 줄었다($r = 0.62$). 수명 말기에도 같은 방향이었다 (0.38).
- 충전 시간이 고정된 Batch 3에서는 최대 C-rate가 높을수록 초기 감소가 빨랐다(0.43). 위의 "전류를 몰아 넣으면 단명"과 같은 방향이다.
- Batch 2는 방향이 일정하지 않았다. 두 실험 방식이 섞인 영향으로 보인다.

설계 반영과 검증 가설

- 정책 이름을 그대로 피처로 쓰지 않고 평균·최대 C-rate로 숫자화한다. Batch 1은 정책당 셀이 2개 안팎이라 이름을 그대로 쓰면 모델이 정책별 정답을 외워 버린다.
- 다른 배치에서는 평균 C-rate가 사실상 상수라서 정책 피처의 기여를 따로 확인하기 어렵다. 넣을지 말지는 Batch 1 검증 결과를 보고 정하려고 한다.
- 현장 검증 후보: 같은 시간 안에 충전해야 할 때 전류를 한 구간에 몰지 않는 방식을 시험해 볼 만하다. 다만 초고속충전 실험에서 본 관계이고 인과관계가 확인된 것은 아니라서, 실제 ESS에 바로 적용하지는 않는다(조건 차이는 1.2절).

4.5 상관관계 — 배치가 바뀌어도 살아남는 신호는 무엇인가

상관계수가 높다고 좋은 피처는 아니다. 배치가 바뀌어도 같은 방향을 가리키는지가 더 중요하다. 그래서 피처 21개를 실험실 피처 (ΔQ), 현장 피처(BMS가 평소 기록하는 용량·내부저항·온도·충전 시간), 충전 정책 피처로 나누고, 세 배치에서 각각 수명과의 상관을 비교했다.

피처 (log 수명과의 상관)	Batch 1	Batch 2	Batch 3	판단
ΔQ log 분산 (실험실)	-0.84	-0.92	-0.76	방향 일관 → 채택
최대 C-rate (충전 정책)	-0.24	-0.20	-0.66	방향 일관 → 보조
충전 시간 (현장)	+0.57	-0.94	+0.60	방향 반전 → 비교용
초기 용량 감소 속도 (현장)	-0.55	+0.42	-0.43	방향 반전 → 비교용
최소 내부저항 (현장)	+0.34	-0.57	+0.17	방향 반전·일부 결측
평균 온도 (현장)	-0.16	+0.39	-0.01	약함·센서 불안정

전체 21개 피처의 상관 행렬은 부록 그림 A2.

- 세 배치 모두에서 강하고 부호가 같은 것은 ΔQ 계열뿐이었다.
- 충전 시간은 Batch 1에서 +0.57, Batch 3에서 +0.60인데 Batch 2에서는 -0.94로 부호가 뒤집혔다. Batch 2 안에 newstructure 그룹(충전 시간이 약간 짧고 수명은 2배)이 섞이면서 생긴 상관으로 보인다. 숫자만 보면 Batch 2에서 가장 강한 피처지만, 진짜 원인은 충전 시간이 아니라 "그룹이 다르다"는 사실이다. 여름에 아이스크림 판매와 물놀이 사고가 같이 나는 것과 비슷하다. 이런 피처를 모델에 넣으면 테스트에서 오히려 오차를 키울 수 있다.

- 평균 온도는 상관이 약하고, 데이터 공개처에서도 열전대 접촉이 불안정하다고 밝히고 있다. 내부저항은 Batch 2의 6개 셀에 기록이 없다.
- 피쳐 중복(다중공선성): ΔQ 의 분산·최소값·평균은 서로 $r \geq 0.98$ 이고, 충전 시간과 평균 C-rate는 $r = -0.99$ 다. 이들을 함께 넣으면 VIF가 수백까지 올라가지만, ΔQ 대표값 1개만 남기면 4.6으로 내려간다.

설계 반영

- 원논문과 Batch 1에서 강한 신호를 보인 ΔQ 계열을 기준 피쳐 세트로 둔다. 중복 피쳐는 대표 1개만 쓰거나 ElasticNet 규제로 정리한다. 다른 배치에서도 방향이 같았던 건 피쳐를 고른 이유가 아니라, "다른 배치에서도 통할 것 같다"는 참고 정보로만 봤다.
- 충전 시간과 초기 감소 기울기는 비교 피쳐 세트에 남겨 두고, 최종 포함 여부는 Batch 1 검증 성능으로 정한다. 다른 배치에서 부호가 바뀐 결과는 해석할 때 주의할 위험 신호다.
- 현장 피쳐만으로는 배치가 바뀌어도 유지되는 신호를 찾지 못했다. 현장에서 ΔQ 를 얻으려면 정기 진단 방전이 필요하다 (6장).

4.6 배치 비교 종합 — DAY 2의 Gap을 미리 예상한다

시험을 본 뒤에 왜 틀렸는지 찾는 것보다, 시험 전에 어디서 틀릴지 예상해 두는 편이 결과를 설명하기 쉽다. 그래서 Batch 1에서 찾은 ΔQ -수명 관계가 다른 배치에서도 유지되는지 미리 봤다. 모델을 학습한 것이 아니라, 같은 관계식을 적용했을 때 어느 쪽으로 치우치는지만 본 진단이다.




그림 8. 그룹별 ΔQ -수명 관계(왼쪽)와 Batch 1 관계식을 그대로 적용했을 때의 치우침(오른쪽, 1.0 = 치우침 없음).

그룹	셀 수	관계 기울기	그룹 내 상관	Batch 1 관계식 대비 실제 수명 (중앙값)
Batch 1	36	-0.30	-0.84	-1%
Batch 2 기존 방식	30	-0.08	-0.38	-24% (30개 모두 관계식보다 짧게 삶)
Batch 2 newstructure	9	-0.16	-0.27	-6%
Batch 3	44	-0.31	-0.76	-2%

Batch 3는 Batch 1과 거의 같은 관계를 따랐다. 반면 Batch 2 기존 방식 30개는 같은 ΔQ 값에서 약 24% 짧게 살았다. Batch 1 관계식을 그대로 쓰면 이 30개는 모두 수명을 길게 잡게 되고, 차이는 중앙값 기준 약 153사이클(+32%)이다. 하루 1회 충방전이라면 교체 시점을 5개월쯤 늦게 잡는 셈이다. 과제 노트에는 Batch 1·2가 비슷하고 Batch 3에서 성능이 떨어질 수 있다고 되어 있지만, 이 데이터에서는 오히려 Batch 2가 더 어려운 시험일 가능성이 높다.

DAY 2 사전 리스크

- Batch 1로 학습한 모델은 Batch 2 기존 방식 셀의 수명을 길게(과대) 예측할 가능성이 높다. 과대예측은 현장에서 교체 시점을 놓치는 쪽이라 더 위험하다. 그래서 MAPE와 함께 과대예측 비율을 따로 보고한다.
- Gap은 그룹별로 나눠 해석한다. 모델 자체의 문제인지, 시험 조건이 달라서인지 구분하기 위해서다.
- 새 생산 로트나 새 운영 조건의 배터리가 들어오면, 소수 샘플로 예측이 맞는지 점검하고 재보정하는 절차가 필요하다고 본다. 재보정 실험은 테스트 정보를 쓰는 것이라 공식 성능표와 분리해서 다룬다.

5. 모델 설계 전략

5.1 EDA 결과를 피처로 연결

후보 피처는 원논문, 과제 정의, Batch 1 분석을 기준으로 구성했다. Batch 2·3에서 본 내용은 피처를 고르는 데 쓰지 않고, 배치 차이를 설명하는 데만 썼다. 최종 피처와 모델은 DAY 2의 Batch 1 교차검증과 Hold-out 결과로 정한다.

EDA 결과	근거	피처	사용
원논문 핵심 신호, Batch 1에서 ΔQ와 수명의 강한 관계 (r -0.84)	4.3	$\log_{10} \text{Var}(\Delta Q_{1_{00-1_0}})$	기준 피처
ΔQ 최소값·평균은 분산과 같은 정보 (r ≥ 0.98)	4.5	$\log \min \Delta Q , \log \text{mean } \Delta Q $	규제 모델 비교용
같은 충전 시간이면 최대 전류↑ → 단명 (-0.68 / -0.66)	4.4	$C_{\max} = \max(C1, C2)$	보조
빠른 충전 → 단명, 초기 열화도 빠름 (Batch 1, -0.58 / 0.62)	4.4	$C_{\text{avg}} (0 \rightarrow 80\% \text{ 평균 } C\text{-rate})$	보조 (테스트 배치에서는 상수)
초기 감소 기울기·충전 시간은 배치 간 해석 위험	4.2, 4.5	fade slope, chargetime	비교 세트에 포함, Batch 1 검증으로 판단
내부저항·온도는 약하고 센서 신뢰도에 제약	4.5	IR, Tavg	현장 피처 세트에서 비교
수명 분포 치우침, 배치 간 스케일 차이, 상대오차 평가	4.1	타깃 $\log_{10}(\text{cycle_life})$	적용
100사이클 용량은 처음과 거의 같음 (+0.2%)	4.2	용량 단독	구분력 없음

DAY 2에서는 피처 세트를 네 단계로 나눠 비교한다. 각 정보가 성능에 얼마나 기여하는지 따로 보기 위해서다.

- A: ΔQ 단일 — 원논문 재현, 기준
- B: A + 충전 정책 — 운영 변수를 넣었을 때의 차이
- C: 전체 후보 + 규제 — 모델이 스스로 고르게 했을 때
- D: 현장 피처만 — ΔQ 없이 실제 ESS 데이터로 어디까지 가능한지

5.2 후보 모델과 선택 이유

후보	알고리즘 관점	데이터 관점 (EDA 근거)	역할
평균 예측	학습 수명 평균을 그대로 예측	—	비교 기준선
선형 회귀 (ΔQ 단일)	직선 관계를 그대로 사용	$\log \Delta Q$ 분산과 $\log$ 수명이 직선 관계 (4.3)	주력 (원논문 재현)

후보	알고리즘 관점	데이터 관점 (EDA 근거)	역할
ElasticNet	규제가 들어간 선형 회귀	피처를 늘리면 $r \geq 0.98$ 중복 발생, 학습 셀 36개 → 규제 필요 (4.5)	확장 모델
트리 계열 (RF, GBM)	스무고개식 분기, 비선형 포착	테스트 수명이 학습 범위 밖 → 범위 밖 예측이 안 되는 한계 (4.1)	비선형 여부 확인용

모델을 고를 때 생각한 것

핵심 피처가 사실상 ΔQ 분산 하나이기 때문에, 처음에는 설명하기 쉬운 단일 피처 선형 회귀를 주력으로 둔다. 피처 하나로는 규제를 걸 이유가 거의 없다. 충전 정책이나 다른 ΔQ 통계를 더해 피처를 늘릴 때만 ElasticNet으로 중복 정보를 규제한다.

- **선형 회귀**: $\log \Delta Q$ 분산과 $\log$ 수명이 거의 직선이라, 계수 하나로 " ΔQ 분산이 변하면 수명이 얼마나 바뀌는지"를 바로 읽을 수 있다. 학습 범위 밖의 값도 직선을 따라 예측할 수 있다.
- **ElasticNet (피처를 늘릴 때, Lasso-Ridge 대신)**: ΔQ 분산·최소값·평균은 서로 거의 같은 정보($r \geq 0.98$)다. Lasso는 이런 피처들 중 하나만 남기고 나머지를 0으로 만드는데, 어떤 걸 남길지가 데이터에 따라 바뀌어서 셀이 36개뿐인 상황에서는 결과가 흔들린다. Ridge는 쓸모없는 피처까지 전부 남긴다. ElasticNet은 비슷한 피처끼리는 가중치를 나눠 갖게 하고, 필요 없는 피처는 0으로 만들어서 둘의 단점을 줄여 준다. 원논문도 ElasticNet을 썼다.
- **트리 계열**: 트리는 잎 노드에 모인 학습 데이터의 평균을 예측값으로 내놓는다. 그래서 학습 데이터에서 가장 긴 수명(Batch 1 정상 셀 1,074)보다 긴 값은 예측할 수 없다. Batch 3는 절반 이상(52%)이 1,000사이클을 넘기 때문에 불리할 가능성이 높다. 그래도 비선형 관계가 있는지 확인하려고 비교 모델로는 넣었다.

최종 모델은 이렇게 고른다

Batch 1 안에서만 비교하고, 아래 순서대로 본다. ① Valid(Hold-out) MAPE가 낮은 모델 ② 실제보다 길게 예측한 비율(과대예측)이 낮은 모델 ③ CV와 Valid 성능 차이가 작은 모델(안정성) ④ 여기까지 비슷하면 더 단순하고 설명하기 쉬운 모델. Batch 2·3 테스트 결과는 모델을 고르는 데 쓰지 않는다.

모델 설정값도 같은 방식으로 정한다. ElasticNet은 규제 강도(alpha)와 L1 비율을, 트리 모델은 깊이와 잎 노드 최소 크기를 충전 정책 단위 교차검증으로 고른다. 셀이 36개뿐이라 탐색 범위는 작게 잡는다.

딥러닝을 쓰지 않는 이유

첫째, 학습에 쓸 수 있는 셀이 36개다. 파라미터가 많은 모델은 이 정도 데이터를 외워 버린다. 둘째, 운영자는 "왜 이 배터리가 일찍 수명을 다한다고 보는지"를 알아야 비용이 큰 교체 결정을 내릴 수 있다. 선형 계열이면 " ΔQ 분산이 10배 커지면 예측 수명이 약 절반이 된다"(Batch 1 기율기 -0.30 기준, $10^{-0.30} \approx 0.5$)처럼 설명할 수 있다. 셋째, 핵심 신호 하나로도 이미 선형 관계가 강하다. 복잡한 모델로 얻을 수 있는 이득보다 설명력과 범위 밖 예측력을 잃는 손해가 더 크다고 봤다.

5.3 데이터 분할과 평가

구분	데이터	방법
Train (CV)	Batch 1	충전 정책 그룹 단위 교차검증 — 같은 정책 셀은 같은 폴드
Valid (Hold-out)	Batch 1 일부	정책 그룹 단위로 약 25% 분리. 모델 선택과 튜닝은 여기까지만 사용
Test	Batch 2	학습·튜닝에는 쓰지 않고 모델을 정한 뒤 한 번만 평가 (DAY 1에서 분포는 이미 확인함)

구분	데이터	방법
Test (추가)	Batch 3	선택 과제. 학습·튜닝과 분리해 1회 평가

공식 지표는 과제 양식대로 MAPE다. Train CV / Valid / Test와 세 구간의 성능 차이(Gap)를 보고하고, 운영 관점에서 아래 세 가지를 더 본다.

- 과대예측 비율: 교체 시점을 놓치는 위험한 방향
- Batch 2 그룹별 오차: 배치 차이의 영향 분리
- 중도 절단 셀의 최소 수명 위반 개수: 장수명을 짧게 예측하는지 점검

표준화 같은 전처리는 학습 데이터로만 맞추고 테스트에는 적용만 한다.

6. 고객사에 드리는 제안

핵심 발견	고객사가 할 일	주의할 점
용량(SOH)만 보면 늦다. 용량은 수명의 약 70% 지점까지 거의 그대로이다가 그 뒤에 급격히 떨어진다.	용량과 함께 초기 지표(ΔQ)도 모니터링	현장에서도 같은 패턴인지 확인 필요
설치 후 약 3개월(100사이클, 하루 1회 기준) 데이터로 단수명 셀을 미리 골라낼 수 있다.	교체 예산·부품을 미리 준비하고, 위험 셀은 더 자주 점검	예측 정확도는 DAY 2에서 확인
초기 지표(ΔQ)는 정기 진단 방전이 있어야 썰 수 있다. 평소 운영 기록(충전 시간·온도 등)만으로는 부족했다.	분기 1회 진단 방전 도입 검토	진단하는 동안 설비 정지·전력 손실 발생
새 로트는 수명이 약 24% 짧을 수 있다. 기존 기준을 그대로 쓰면 교체 시점을 약 5개월 늦게 잡게 된다.	새 로트는 일부를 먼저 확인한 뒤 예측 기준 보정	수명을 길게 보면 갑작스러운 설비 정지로 이어짐
같은 충전 시간이라도 전류를 고르게 나누면 수명이 길었다. 같은 10분 충전에서 최대 2배 이상 차이가 났다.	충전 설정을 바꿔 소규모로 시험	10분 고속충전 실험 결과라 일반 ESS에서 확인 필요

비용: 배터리 교체비는 ESS 설치비의 30~40%이고, 셀 교체비는 1MWh당 \$30,000~\$80,000(약 4,200만~1억 1,200만 원)이다. 교체 시점을 미리 알면 갑작스러운 정지와 불필요한 초기 교체를 줄일 수 있으며, 실제 절감액은 DAY 2의 예측 오차를 이 비용에 대입해 계산할 예정이다.

위 내용은 실험실 데이터로 얻은 1차 결과이며, 현장 데이터로 검증한 뒤 적용한다.

7. 리스크, 한계와 다음 단계

리스크·한계	대응
Batch 2 기존 방식 셀을 길게 예측할 가능성 (4.6)	그룹별 Gap과 과대예측 비율을 따로 보고
장수명 셀 부족 → 긴 수명을 짧게 예측할 가능성 (2장)	중도 절단 셀로 최소 수명 점검
실험실과 실제 ESS의 조건 차이 (1.2)	현장 데이터로 재학습·재검증
현장에서 ΔQ 를 얻기 어려움 (4.5)	정기 진단 방전의 비용·효과 검토 (6장)
학습 셀 36개	단순·규제 모델, 정책 단위 검증

다음 단계는 세 가지로 생각하고 있다.

1. DAY 2: Batch 1에서 피쳐 세트 A~D와 후보 모델을 비교·확정하고, Batch 2에서 성능 차이와 오류를 분석한다.
2. 운영 1단계: 실제 ESS의 BMS 데이터와 정기 진단 방전으로 다시 검증한다.
3. 운영 2단계: 생존 분석과 로트 재보정을 자동화하고, 교체 예산 계획과 연결한다.

부록




그림 A1. 무릎점 위치와 수명의 관계(왼쪽), 초기와 수명 말기의 열화 속도 비교(오른쪽, 로그축).




그림 A2. 배치별 수명 상관(왼쪽)과 Batch 1 피쳐 간 상관(오른쪽, $|r| \ge 0.8$ 만 표기). fade_slope_2_100은 용량 변화 기울기 원값이라 본문의 "감소 속도"와 부호가 반대다.

분석 중 내린 결정과 이유, 검토한 대안은 DECISIONS.md에, 보고서 숫자 검증 코드는 src/verify_report_numbers.py에 있다.